

# 统计学习第六章

贾金柱

Nov 21, 2017

# 讲课老师

- 主讲人： 贾金柱
  - Email: [jzjia@math.pku.edu.cn](mailto:jzjia@math.pku.edu.cn)
- 助教： 肖一君
  - Email: [xiaoyijun1994@126.com](mailto:xiaoyijun1994@126.com)

# 第六章 SVM

- 课程目标
  - linear SVM
  - Nonlinear SVM
  - SVM Regression

# Linear SVM

- training data  $(x_i, y_i), i = 1, 2, \dots, n,$   
 $y_i \in \{-1, +1\}, x_i \in \mathbb{R}^p.$

- 定义一个 Classifier:

$$G(x) = \text{sign}(x^T \beta + \beta_0)$$

- 首先假设数据是完全线性可分的，即所有的数据点满足

$$y_i(x_i^T \beta + \beta_0) \geq 1.$$

- 那么最好的分割线应该使得两组数据尽可能地分开，即

$$\begin{aligned} & \max \frac{2}{\|\beta\|_2} \\ & s. t. y_i(x_i^T \beta + \beta_0) \geq 1. \end{aligned}$$

# Linear SVM

$$\begin{aligned} \min \quad & \frac{1}{2} \|\beta\|_2^2 \\ \text{s.t.} \quad & y_i(x_i^T \beta + \beta_0) \geq 1. \end{aligned}$$

- 通常数据不会完美分开。因此， 需要引入松弛因子：

$$\begin{aligned} \min \quad & \frac{1}{2} \|\beta\|_2^2 \\ \text{s.t.} \quad & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \\ & \xi_i \geq 0 \\ & \sum_{i=1}^n \xi_i \leq \text{constant} \end{aligned}$$

# Linear SVM

$$\begin{aligned} \min \quad & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \\ & \xi_i \geq 0 \end{aligned}$$

- 这是一个有线性约束的凸二次规划
- 可以通过QP (quadratic programming) 解决
- 也可以通过Lagrange 对偶问题求解

# SVM

- SVM 示意图




图: SVM 示意图

# Lagrange Dual Problem

- Lagrange function:

$$L(\beta, \beta_0, \xi, \alpha, \mu) = \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i(x_i^T \beta + \beta_0) - (1 - \xi_i)] - \sum_{i=1}^n \mu_i \xi_i$$

- 记SVM的最优值是 $p^*$ .
- 易知

$$\min_{\beta, \beta_0, \xi} \max_{\alpha > 0, \mu > 0} L(\beta, \beta_0, \alpha, \mu) = p^*$$



# Lagrange Dual Problem

- 对偶问题 (Dual Problem)

$$\max_{\alpha > 0, \mu > 0} \min_{\beta, \beta_0, \xi} L(\beta, \beta_0, \xi, \alpha, \mu) := d^*$$

- 性质:

$$d^* \leq p^*$$

# 求解对偶问题

分两步,

- 对于任意  $\alpha, \mu$ , 求  $L$  关于  $\beta, \beta_0, \xi$  的最小值, 得到  $\theta(\alpha, \mu)$
- 然后求  $\theta(\alpha, \mu)$  的最大值

$$\frac{\partial L}{\partial \beta} = 0 \Rightarrow \beta = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial \beta_0} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C - \alpha_i - \mu_i = 0$$

# 求解对偶问题

将  $\beta$  带入  $L(\beta, \dots)$  并化简, 得到

$$\theta(\alpha, \mu) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$$

最后, 对偶问题可以正式描述如下

$$\begin{aligned} \max \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s. t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

# SVM的解

一旦通过对偶问题，求得  $\alpha$ ，即可通过下式求得  $\beta$ ，

$$\beta = \sum_{i=1}^n \alpha_i y_i x_i$$

KKT condition 告诉我们：

$$\alpha_i [y_i (x_i^T \beta + \beta_0)] = 0$$

由此，可以求得  $\beta_0 = y_k x_k^T \beta$ , for some  $k$  with  $\alpha_k \neq 0$

# SVM的解

最后, classifier 就是  $\text{sign}(f(x))$ ,

$$\begin{aligned} f(x) &= x^T \hat{\beta} + \hat{\beta}_0 \\ &= x^T \hat{\beta} - y_k x_k^T \hat{\beta} \\ &= x^T \sum_{i=1}^n \alpha_i y_i x_i - y_k x_k^T \sum_{i=1}^n \alpha_i y_i x_i \\ &= \sum_{i=1}^n \alpha_i y_i \langle x, x_i \rangle - y_k \sum_{i=1}^n \alpha_i y_i \langle x_k, x_i \rangle \end{aligned}$$

# SVM 总结

- 它是一个带有线性约束的二次规划问题
- 转到对偶问题，更容易求解
- 特别的，转到对偶问题，我们发现：
  - 参数  $\alpha_i, i = 1, 2, \dots, n$  仅依赖于样本点的内积  $\langle x_i, x_k \rangle$
  - classifier 也仅依赖于样本点的内积  $\langle x, x_i \rangle$ ,  $x$  可以是测试样本或者观测样本

# Kernel SVM

- 将数据映射到高维空间（比如泛函空间）

$$x_i \mapsto \phi(x_i, \cdot)$$

- 定义内积

$$\langle \phi(x_i, \cdot), \phi(x_k, \cdot) \rangle = K(x_i, x_k)$$

- 求解 SVM

$$\begin{aligned} \max \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{s.t.} \quad & \sum_{i=1}^n \alpha_i y_i = 0, \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, n \end{aligned}$$

# Kernel SVM的解

最后， classifier 就是  $\text{sign}(f(x))$ ,

$$f(x) = \sum_{i=1}^n \alpha_i y_i \langle x, x_i \rangle - y_k \sum_{i=1}^n \alpha_i y_i \langle x_k, x_i \rangle$$



# SVM 的另一种表达

$$\min_{\beta, \beta_0} \sum_{i=1}^N [1 - y_i f(x_i)]_+ + \frac{\lambda}{2} \|\beta\|_2^2$$

证明： 上式可以重新表达

$$\begin{aligned} \min_{\beta, \beta_0} \quad & \sum_{i=1}^N \xi_i + \frac{\lambda}{2} \|\beta\|_2^2 \\ \text{s. t.} \quad & 1 - y_i f(x_i) \leq \xi_i \\ & \xi_i \geq 0 \end{aligned}$$

# Generalize SVM to Regression

One regression problem:

$$\begin{aligned} \min \quad & \frac{1}{2} \|\beta\|_2^2 \\ \text{s.t.} \quad & y_i - x_i^T \beta - \beta_0 \leq \epsilon \\ & y_i - x_i^T \beta - \beta_0 \geq -\epsilon \end{aligned}$$

# SVM Regression

引入松弛因子：

$$\begin{aligned} \min \quad & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ \text{s. t.} \quad & y_i - x_i^T \beta - \beta_0 \leq \epsilon + \xi_i \\ & x_i^T \beta + \beta_0 - y_i \leq \epsilon + \xi_i^* \\ & \xi_i, \xi_i^* \geq 0 \end{aligned}$$

# Dual Problem

定义Lagrangian

$$\begin{aligned} L := & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \\ & - \sum_{i=1}^n \alpha_i (\epsilon + \xi_i - y_i + x_i^T \beta + \beta_0) \\ & - \sum_{i=1}^n \alpha_i^* (\epsilon + \xi_i^* + y_i - x_i^T \beta - \beta_0) \\ & + \sum_{i=1}^n (\eta_i \xi_i + \eta_i^* \xi_i^*) \end{aligned}$$

其中  $\alpha_i, \eta_i, \alpha_i^*, \eta_i^* \geq 0$

# Dual Problem

$$\frac{\partial L}{\partial \beta} = 0 \Rightarrow \beta = \sum_{i=1}^n ( \alpha_i^* - \alpha_i ) x_i$$

$$\frac{\partial L}{\partial \beta_0} = 0 \Rightarrow \sum_{i=1}^n ( \alpha_i^* - \alpha_i ) = 0$$

$$\frac{\partial L}{\partial \xi^{(*)}} = 0 \Rightarrow C - \alpha_i^{(*)} - \eta_i^{(*)} = 0$$

# Dual Problem

$$\begin{aligned} \max & -\frac{1}{2} \sum_{i,j=1}^n (\alpha_i - \alpha_i^*)(\alpha_j - \alpha_j^*) \langle x_i, x_j \rangle \\ & - \epsilon \sum_{i=1}^n (\alpha_i + \alpha_i^*) + \sum_{i=1}^n y_i (\alpha_i - \alpha_i^*) \\ \text{s. t. } & \sum_{i=1}^n (\alpha_i - \alpha_i^*) = 0 \\ & \alpha_i, \alpha_i^* \in [0, C]. \end{aligned}$$

# SVM Regression

$$\beta = \sum_{i=1}^n ( \alpha_i^* - \alpha_i ) x_i,$$

So,

$$f(x) = x^T \beta = \sum_{i=1}^n (\alpha_i^* - \alpha_i) \langle x, x_i \rangle + \beta_0$$

- Easily extend to non-linear SVM regression!

# code

我推荐 <http://svmlight.joachims.org>